Универзитет „Св. Кирил и Методиј“ во Скопје
Факултет за информатички науки и компјутерско инженерство

Дипломска работа

Способноста на мали јазични модели за промена на стил на македонски автори со примена на учење со поттикнување

[*Ментор: ...*] [*Кандидат: ...*]

Скопје, 2026

Апстракт

[*Апстракт --- written last (problem, method, the negative result with three or four numbers).*]

Содржина

1 Вовед **3**
- 1.1 Мотивација . . . 3
- 1.2 Истражувачко прашање . . . 3
- 1.3 Пристап и главен наод . . . 4
- 1.4 Придонеси . . . 4
- 1.5 Структура на работата . . . 5

2 Преглед на областа **6**
- 2.1 Пренос на стил на текст . . . 6
- 2.2 Стилометрија и утврдување авторство . . . 7
- 2.3 Дестилација на знаење и адаптација со низок ранг . . . 7
- 2.4 Учење со поттикнување кај јазичните модели . . . 8
- 2.5 Обработка на македонскиот јазик . . . 8

3 Data **9**
- 3.1 The corpus . . . 9
- 3.2 Cleaning . . . 10
- 3.3 Tagging and corrections . . . 10
- 3.4 Splits . . . 11
- 3.5 How little data there is . . . 11

4 Stylometric foundation **12**
- 4.1 Author style profiles . . . 12
- 4.2 TF-IDF palettes . . . 12
- 4.3 The semantic knowledge graph . . . 12
- 4.4 Two author classifiers . . . 12
- 4.5 Validation of the pipeline . . . 12

5 The path to a teacher **13**
- 5.1 Word substitution . . . 13
- 5.2 LLM infilling . . . 13
- 5.3 A scaffolded prompt for a large model . . . 13

6 Method **14**
- 6.1 The teacher and the synthetic data . . . 14
- 6.2 Task format . . . 14
- 6.3 Supervised fine-tuning . . . 14
- 6.4 Reward . . . 14
- 6.5 GRPO . . . 14

6.6 The second student: Gemma 4 E4B 14

7 Evaluation setup **15**
7.1 Protocol 15
7.2 Metrics 15
7.3 The judge 15
7.4 A decoding baseline 15
7.5 Human evaluation 15

8 Results **16**
8.1 Earlier approaches against the students 16
8.2 Qwen3-4B: validation and test 16
8.3 Author identification per target 16
8.4 The decoding baseline 16
8.5 The teacher 16
8.6 Gemma 4 E4B against Qwen3-4B 16
8.7 Human ratings 16

9 Discussion **17**
9.1 Why the students fail 17
9.2 The teacher's own limits 17
9.3 Threats to validity 17

10 Conclusion **18**
10.1 Future work 18

A Examples **19**
A.1 One example per stage 19

Б Prompts and hyperparameters **20**
Б.1 Teacher prompt 20
Б.2 Student prompt 20
Б.3 Training configuration 20

В Reproducibility **21**
В.1 Commands 21

Глава 1

Вовед

1.1 Мотивација

Стилот на еден автор е она што останува од песната кога ќе се смени нејзината тема: зборовите по кои посегнува авторот, должината на стиховите, дали има рима и каква, каква слика остава. Не е едноставно да се препише една песна во стил на друг автор, а патем да се задржи содржината. Ова е тежок тест за дали јазичниот модел го научил тој слој на јазикот. Ова е задачата на *пренос на стил на текст* (text style transfer), во најтежок облик: „стилот“ не е нешто објективно, како формален или неформален говор. Не секогаш има еден точен одговор.

Најголемиот дел од истражувањата за пренос на стил, и за јазичните модели воопшто, се прават на англиски јазик, каде што податоците се изобилни. Македонскиот јазик е со ограничени ресурси: има малку анотирани корпуси, малку алатки, и сочинува мал дел од текстовите на кои се обучуваат општите модели. Поезијата ја влошува оваа состојба. Еден поет во текот на животот пишува неколку стотини песни, често и многу помалку, па дури и целокупниот корпус на еден автор е мало податочно множество според мерилата на машинско учење. Корпусот на врз кој е изградена оваа работа содржи 1.239 песни и текстови на песни од 38 македонски автори; најзастапениот автор има 182 песни, следните двајца 160 и 134, а половина од авторите имаат седумнаесет или помалку.

Големите модели можат со соодветно барање (prompt) да пишуваат во даден стил, но нивното извршување е скапо и не е под контрола на корисникот. Малите модели, со неколку милијарди параметри, можат да се обучуваат и извршуваат на една графичка картичка, што ги прави практичен избор за јазични задачи без големи пресметковни ресурси. Дали можат да научат задача толку специфична како гласот на одреден поет, и тоа од толку малку податоци, е прашањето на кое оваа работа се обидува да одговори.

1.2 Истражувачко прашање

Работата го поставува следното прашање:

> *Може ли мал јазичен модел, кому му се дадени само изворна песна и името на македонски автор, да ја препише песната во стилот на тој автор, и дали учењето со поттикнување го подобрува резултатот?*

Два дела од прашањето бараат појаснување. „Во стилот на тој автор“ се мери на два меѓусебно независни начини: автоматски, преку стилометриски карактеристики

и преку класификатор на автори што обуката никогаш не го гледа, и преку човечка проценка. „Учење со поттикнување“ (reinforcement learning) е методот Group Relative Policy Optimization (GRPO)[1] [24], применет по надгледуваното фино подесување, со награда изградена од стилометрискиот профил на секој автор.

1.3 Пристап и главен наод

Работата го доби својот конечен облик по неколку пристапи што не успеаја. Замената на избрани зборови од изворната песна со зборови карактеристични за целниот автор, соодветно менувани по форма, ја зачувува песната, но малку го менува нејзиниот стил. Кога од мали локални модели се бара да ги пополнат таквите празни места, тие не успеваат веќе на ниво на македонскиот јазик. Она што успеа е голем модел, Gemma 4 31B [6], на кој му е дадено детално структурирано барање: резиме на изворната песна, опис на стилот на целниот автор во проза, палета од зборови и примерни стихови, и експлицитни структурни цели. Тој модел стана *учител*. Неговите песни, околу 115 за секој од десетте целни автори, се податоците за обука на двајца *ученици* со слична големина, Qwen3-4B [33] и Gemma 4 E4B, кои ги гледаат само изворната песна и името на авторот. Секој ученик најпрвин се фино подесува со LoRA [9] врз песните на учителот, а потоа понатаму се обучува со GRPO.

Главниот наод е негативен. Учениците ја научуваат формата на задачата: пишуваат на македонски, пишуваат песни, а не проза, и ја менуваат изворната песна наместо да ја препишат. Гласовите не ги научуваат. Независен класификатор на автори го препознава бараниот автор кај 16,7% од песните на фино подесениот ученик Qwen на тест-паровите, наспроти 66,3% кај вистински, невидени песни од истите автори; по GRPO оваа бројка паѓа на 12,4%, иако наградата што методот ја оптимизира расте. Учителот, пак, со целиот опис на авторот пред себе, го постигнува тоа кај 53,6% од своите песни. [*Резултати за ученикот Gemma и човечката проценка.*] Препознаените песни на учениците речиси сите им припаѓаат на трите автори со најмногу песни во корпусот, додека учителот успешно имитира и некои автори со помалку од четириесет песни.

Работата тврди дека ограничувањето е во податоците, а не во методот. Корпусот е доволен за учителот да имитира автор кога доказите за неговиот стил му се дадени во секое барање; не е доволен ученикот да го научи тој стил и да го задржи во своите параметри од околу 115 примери по автор. Посилен ученик, подобро подесена награда и учењето со поттикнување не ја надминуваат оваа граница.

1.4 Придонеси

- Исчистен корпус на македонска поезија, означен со зборовни видови, со идентификатори на ниво на песна, документирани корекции на означувањето и фиксна поделба по автор на множества за обука, валидација и тестирање.
- Стилометриски профили на авторите и награда за пренос на стил изградена од нив: распределби на зборовни видови, лексичка разновидност, структура на стихови и

[1] Според Правописот на македонскиот литературен јазик (2017), називите од туѓо потекло се предаваат со кирилско писмо, но се допуштаат и латинични скратеници. Во оваа работа називите на моделите, методите и алатките (Qwen, Gemma, LoRA, GRPO и сл.) се пишуваат оригинално, на латиница, за да се избегне обременување на текстот и за да се препознаваат при пребарување литература од областа.

строфи, рима, карактеристичен речник и класификатор на автори, со порти (gates) против препишување на изворот и против дегенериран излез.

- Систем учител–ученик што го дестилира големиот модел со структурирано барање во двајца мали ученици, по што следи GRPO, со исти поставки за двајцата ученици за да можат нивните резултати да се споредат.
- Евалуација што ги одделува вистинските подобрувања од „измамата“ на наградата: класификаторот што се користи како награда никогаш не се користи за проценка на резултатот; тоа го прави втор класификатор, обучен врз други карактеристики.
- Човечка проценка на учителот, двајцата ученици и вистински песни врз истите тест-парови, со вистинските песни како слепа контрола.

1.5 Структура на работата

Поглавјето 2 дава преглед на преносот на стил на текст, стилометријата, дестилацијата на знаење и учењето со поттикнување кај јазичните модели. Поглавјето 3 го опишува корпусот и неговата подготовка, а Поглавјето 4 стилометриските профили и класификаторите врз кои се потпира остатокот од работата. Поглавјето 5 ги сумира претходните пристапи и причините зошто беа напуштени. Поглавјето 6 ги претставува учителот, учениците и наградата, а Поглавјето 7 протоколот за евалуација. Поглавјето 8 ги дава резултатите, Поглавјето 9 дискутира зошто учениците заостануваат, а Поглавјето 10 ја заклучува работата.

Глава 2

Преглед на областа

2.1 Пренос на стил на текст

Преносот на стил на текст го препишува текстот така што се менува едно негово својство, стилот, а содржината останува иста [10]. Што се смета за стил зависи од задачата: сентимент, формалност, учтивост или начинот на пишување на одреден автор. Последниот вид е најстариот пример во областа: Xu et al. [32] го парафразираа современиот англиски јазик во Шекспировиот и обратно, користејќи ги паралелните современи верзии на неговите драми.

Надгледуван пренос. Кога постојат паралелни податоци, парови текстови со иста содржина во два стила, задачата е обично учење од секвенца во секвенца. Најпознатото такво множество, GYAFC, има околу 110.000 парови неформални и формални реченици, напишани од луѓе ангажирани преку платформи за краудсорсинг [21]. Паралелни податоци за стилот на одреден автор практично не постојат: никој не ја пишува истата песна двапати, со гласовите на двајца поети.

Ненадгледуван пренос. Затоа поголемиот дел од литературата работи со непаралелни податоци, текстови во секој стил што не се преводи еден на друг. Едно такво истражување ги одделува содржината и стилот во латентна репрезентација и ја декодира содржината со друг стил [25]. Друго пак директно го уредува текстот: ги брише зборовите што го означуваат изворниот стил и ги пополнува празнините со зборови типични за целниот стил [14]. Трет труд го третира преносот како парафразирање: модел за парафразирање најпрвин го отстранува стилот, а модел обучен врз текстови од еден стил потоа ја препишува неутралната парафраза во тој стил [12]. И тука е применето учење со поттикнување, со награди за целниот стил и за зачувување на содржината [17].

Барања до големи модели. Големите јазични модели можат да вршат пренос на стил без никаква обука, само со инструкција и неколку примери во барањето (prompt) [22]. Методите со пополнување (infilling) го постигнуваат уредувањето на текстот со праќање барања до моделот: зборовите што го носат стилот се означуваат или маскираат, а јазичниот модел ги избира нивните замени, така што остатокот од текстот, а со него и содржината, останува непроменет [15]. Вториот од претходните пристапи во оваа работа (Поглавје 5) го следи овој дизајн.

Поезија и авторски стил. Поезијата додава ограничувања што прозата ги нема: стихови, строфи, метрика и рима. Tikhonov and Yamshchikov [29] генерираат поезија во стилот на одредени автори, на англиски и на руски јазик, и ги оценуваат резултатите и автоматски и со човечки читатели. Нивните модели генерираат нови песни од корпусот на авторот; задачата во оваа работа е во еден поглед потешка, бидејќи генерираната песна мора да ја задржи и содржината на дадена изворна песна, напишана од друг автор.

2.2 Стилометрија и утврдување авторство

Стилометријата го мери стилот преку пребројливи карактеристики на текстот, а нејзината главна примена е утврдување авторство: одлучување кој го напишал дадениот текст [27]. Класичната студија на спорните текстови *Federalist* покажа дека честотите на чести функциски зборови, кои авторот ги користи без да размислува за нив, го откриваат авторот подобро отколку содржината [18]. Мерката Delta на Burrows [1], растојание врз стандардизирани честоти на најчестите зборови, е стандардна основа. Современото утврдување авторство комбинира многу видови карактеристики (n-грами од зборови и знаци, шеми на зборовни видови, лексичко богатство, должина на реченици и стихови) со надгледуван класификатор [27]. Лексичкото богатство зависи од должината на текстот, па за да се споредуваат кратки и долги песни потребна е мерка што не расте со текстот; подвижниот просечен однос на типови и појавници (MATTR) го пресметува односот во лизгачки прозорец со фиксна големина [3].

Оваа работа ја користи стилометријата во две улоги. Профилот на карактеристиките на секој автор дефинира што бара наградата, а класификатор на автори мери дали генерираната песна звучи како песна на тој автор. Кога истиот класификатор и добива награда, и се користи за мерење на успехот, моделот може да научи да го задоволи класификаторот без да пишува како авторот. Затоа евалуацијата користи втор класификатор што обуката никогаш не го гледа (Поглавје 4).

2.3 Дестилација на знаење и адаптација со низок ранг

Дестилацијата на знаење обучува мал модел, *ученик*, да имитира поголем модел, *учител* [8]. За генерирање текст наједноставната и најефикасната форма го обучува ученикот врз излезите на учителот, како да се референтни податоци (дестилација на ниво на секвенца, 11). Големите јазични модели го практикуваат ова како вообичаен начин за градење податоци за обука: силен модел пишува примери за задачата, а помал модел се фино подесува врз нив [31]. Учениците во оваа работа се обучуваат на истиот начин, врз песни напишани од учителот.

Финото подесување на сите тежини на модел со милијарди параметри бара повеќе меморија отколку што има една графичка картичка. Адаптацијата со низок ранг (LoRA, 9) ги замрзнува оригиналните тежини и, за избрани тежински матрици, учи корекција во облик на производ на две мали матрици. Параметрите што се обучуваат се дел од процентот на моделот, а по обуката корекцијата може да се спои со тежините.

2.4 Учење со поттикнување кај јазичните модели

Надгледуваното фино подесување го учи моделот да имитира примери. Учењето со поттикнување, пак, му дозволува на моделот да генерира, го оценува секој излез со *награда* и го менува моделот така што излезите со висока награда стануваат поверојатни. Кај јазичните модели наградата најпрвин се учеше од човечки преференции меѓу парови излези [2, 34]; ова учење со поттикнување од човечка повратна информација (RLHF) е начинот на кој се обучуваат агентите кои следат инструкции [19]. Алгоритмот за оптимизација во тој труд е Proximal Policy Optimization (PPO, 23), кој, покрај моделот што се обучува, користи и втора мрежа со слична големина за проценка на вредноста на секоја состојба.

Group Relative Policy Optimization (GRPO, 24) ја отстранува таа втора мрежа. За секое барање генерира група излези, ги оценува, и како предност (advantage) ја користи наградата на секој излез во однос на средната вредност и стандардната девијација на неговата група. Казна за отстапувањето од референтниот модел го држи обучуваниот модел блиску до почетната точка. GRPO е воведен за математичко расудување, а подоцна се користи за обука на модели за расудување со награди што можат автоматски да се проверат [7]. Тука наградата се пресметува, а не се учи од преференции: тоа е стилометрискиот профил на целниот автор заедно со мерка за зачуваноста на содржината.

Секоја награда е само приближување до она што се бара, а модел што доволно силно ја оптимизира наоѓа начини да добие висока оценка без да ја изврши задачата. Оваа *измама на наградата* (reward hacking, 26) расте со јачината на оптимизацијата [5], и затоа наградата и евалуацијата во оваа работа користат различни мерења. Обуката ја користи библиотеката TRL [30].

2.5 Обработка на македонскиот јазик

Македонскиот е јужнословенски јазик што се пишува на кирилица, со богата глаголска морфологија, постпозитивен определен член со три форми и речиси без падежи кај именките. Има многу помалку ресурси од англискиот или од поголемите словенски јазици. Проектот CLASSLA нуди означување и лематизација за јужнословенските јазици, изградени врз алатката Stanza [20, 16, 28]; неговите модели за македонски доделуваат лема на секој збор, универзален облик на зборот и морфосинтаксички опис според MULTEXT-East [4]. Големите општи модели пишуваат на македонски, но со отстапки во граматиката и во усогласувањето на зборовите [35], а малите отворени модели што се користат како ученици во оваа работа се обучени врз многу малку текст на македонски. Првиот отворен основен модел изграден специјално за македонски, со модел од 8 милијарди параметри, корпус од 3,5 милијарди зборови, множество инструкции и мерно множество од седум задачи, се појавува дури во 2025 година [13].

Глава 3

Data

3.1 The corpus

The corpus holds 1,239 Macedonian poems and song lyrics by 38 authors, 130,059 whitespace-separated tokens in all. Every poem has four fields: a numeric identifier, the author, the title and the text, in Cyrillic script with one verse per line and blank lines between stanzas. A typical poem is short: the median poem has 17 lines and 81 tokens.

The authors are very unevenly represented (Table 3.1). Three of them, Блаже Конески, Пијан Славеј and Ефтим Клетников, account for 476 poems, 38% of the corpus. The next author has 70. Half of the 38 authors have 17 poems or fewer, and eight have only one or two. Only 24 authors have at least five poems; these are the authors for whom a stylometric profile is built (Chapter 4), and the remaining 14 appear in the data only as poems, never as targets of style transfer.

Author	Corpus	Train split	Teacher examples
Блаже Конески	182	146	109
Пијан Славеј	160	128	108
Ефтим Клетников	134	108	110
Славко Јаневски	70	56	120
Влада Урошевиќ	61	49	114
Катица Ќулавкова	60	48	114
Братислав Ташковски	56	44	114
Веле Смилевски	49	39	118
Ристо Лазаров	48	38	120
Адем Гајтани	45	37	119
Other 28 authors	374	294	---

Табела 3.1: Poems per author for the ten target authors: in the whole corpus, in the training split, and synthetic training examples written by the teacher model with that author as the target (Chapter 6).

3.2 Cleaning

Poem identifiers. An author and a title do not identify a poem: about fifteen (author, title) pairs are shared by several different poems, Блаже Конески alone having four poems titled *Песна*. Every poem is therefore given a stable numeric identifier, and every later stage, from the splits to the generated outputs, refers to poems by that identifier.

Script artefacts. 52 poems contain a Latin or Greek letter. In about 22 of them the letter is an artefact of digitisation: a character that looks like a Cyrillic one but has a different code point, such as a Greek *ο* standing for the vocative *о*, or words that mix two scripts, such as *што* or *КАМЕН*. The rest are intentional: Roman numerals and about thirty poems with whole words in Latin script. The two cases are kept apart. Artefacts are flagged during tagging and corrected by hand (below); intentional foreign words are left as they are.

3.3 Tagging and corrections

The corpus is tagged with CLASSLA-Stanza [*cite: Ljubešić and Dobrovoljc 2019; Terčon and Ljubešić 2023*], using its Macedonian models, which give for every token a lemma, a universal part-of-speech tag, a MULTEXT-East morphosyntactic tag [*cite: Erjavec 2012*] and morphological features. A hand check of 70 randomly chosen tokens against their lines put the accuracy of the part-of-speech tag at about 96%. The stylometric work uses only content words (nouns, proper nouns, verbs, adjectives and adverbs): 70,531 tokens.

Three corrections are applied on top of the tagger's output:

1. *Hand corrections.* A file of corrections, each keyed on a word and the tag judged wrong, is applied first, so that correctly tagged occurrences of the same word are never rewritten. A correction can change the tag, the lemma, or drop the token (for noise such as timestamps). There are currently 90.

2. *Relativisers.* The tagger labels the relativisers *што*, *кога*, *како*, *колку* and *каде* as adverbs. Left in, they were the five most frequent ``content'' words in the corpus, 1,478 tokens or 19% of all adverbs, and distorted every part-of-speech ratio built on adverbs. They carry a bare adverb tag without a degree, which real adverbs always have, and are filtered on that.

3. *Verbal adverbs.* Forms in *-јќи* (*барајќи*) are left unlemmatised by the tagger. They are re-lemmatised to their base verb; where the ending is ambiguous (*велејќи* from *вели*, but *знаејќи* from *знае*) the more frequent verb lemma in the corpus is chosen.

Every tagging run also writes an audit of suspicious tokens, 1,813 at present, grouped by reason: the two tag layers disagree on the word class (675 tokens), a lowercase word is tagged as a proper noun (430), the tagger gives no tag (357, mostly dialectal clippings such as *ко* and *сал*), a form is tagged differently from its majority reading elsewhere in the corpus (311), and script artefacts (40). The audit is the review queue for new hand corrections; nothing is filtered on it directly. Rules that flagged tokens for being rare were tried and dropped: in poetry rare words and lines without a verb are normal, and such rules were right about 5% of the time.

3.4 Splits

The poems are split into training, validation and test sets in the ratio 80/10/10 within each author, with a fixed random seed: 987, 126 and 126 poems. Splitting by author guarantees that every author with at least three poems has at least one poem in each set; the eight authors with one or two poems go entirely to the training set. The split is by poem, so two poems that share an author and a title can fall into different sets.

The split is computed once and read by every later stage. Everything that is learned from data (style profiles, classifiers, the teacher's examples, both students and the reward) uses training poems only. The validation set is used for model selection and for every comparison made during development; the test set is used once, for the final numbers in Chapter 8.

3.5 How little data there is

For a task as specific as writing like one poet, this is very little data. Even the best represented author has 146 poems in the training split, and seven of the ten target authors have between 37 and 56 (Table 3.1). By comparison, style-transfer benchmarks such as [*cite: GYAFC (Rao and Tetreault 2018)*] have tens of thousands of parallel sentence pairs for a single, much coarser style distinction.

The synthetic data does not remove this limit. The teacher writes about 115 examples for each target author, a balanced set, but each example is built from the same training poems: the description of the author's style, the vocabulary and the example lines in the teacher's prompt all come from them. An author with 37 poems in the training split is therefore represented by 37 poems' worth of style, however many examples are written from it. Chapter 9 returns to this: the students identifiably imitate only the three authors with more than a hundred training poems.

Глава 4

Stylometric foundation

4.1 Author style profiles

[*to write*]

4.2 TF-IDF palettes

[*to write*]

4.3 The semantic knowledge graph

[*to write*]

4.4 Two author classifiers

[*The reward classifier and the independent judge.*]

4.5 Validation of the pipeline

[*Tagger migration, fixed bugs, community artifact.*]

Глава 5

The path to a teacher

5.1 Word substitution

[*to write*]

5.2 LLM infilling

[*to write*]

5.3 A scaffolded prompt for a large model

[*Which becomes the teacher.*]

Глава 6

Method

6.1 The teacher and the synthetic data

[*to write*]

6.2 Task format

[*to write*]

6.3 Supervised fine-tuning

[*to write*]

6.4 Reward

[*Style, content, gates, weights from within-group spread.*]

6.5 GRPO

[*Merge-then-LoRA, hyperparameters, v1 and v2.*]

6.6 The second student: Gemma 4 E4B

[*to write*]

Глава 7

Evaluation setup

7.1 Protocol

[*to write*]

7.2 Metrics

[*to write*]

7.3 The judge

[*to write*]

7.4 A decoding baseline

[*to write*]

7.5 Human evaluation

[*to write*]

Глава 8

Results

8.1 Earlier approaches against the students

[*to write*]

8.2 Qwen3-4B: validation and test

[*to write*]

8.3 Author identification per target

[*to write*]

8.4 The decoding baseline

[*to write*]

8.5 The teacher

[*to write*]

8.6 Gemma 4 E4B against Qwen3-4B

[*to write*]

8.7 Human ratings

[*to write*]

Глава 9

Discussion

9.1 Why the students fail

[*Data scale, style collapse, nothing for the group advantage to amplify, reward gaming.*]

9.2 The teacher's own limits

[*to write*]

9.3 Threats to validity

[*to write*]

Глава 10

Conclusion

10.1 Future work

[*to write*]

Прилог A

Examples

A.1 One example per stage

[*to write*]

Прилог Б

Prompts and hyperparameters

Б.1 Teacher prompt

[*to write*]

Б.2 Student prompt

[*to write*]

Б.3 Training configuration

[*to write*]

Прилог B

Reproducibility

B.1 Commands

[*to write*]

Библиографија

[1] John Burrows. `Delta': a measure of stylistic difference and a guide to likely authorship. *Literary and Linguistic Computing*, 17(3):267--287, 2002. doi: 10.1093/llc/17.3.267.

[2] Paul F. Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/d5e2c0adad503c91f91df240d0cd4e49-Abstract.html.

[3] Michael A. Covington and Joe D. McFall. Cutting the Gordian knot: The moving-average type--token ratio (MATTR). *Journal of Quantitative Linguistics*, 17(2):94--100, 2010. doi: 10.1080/09296171003643098.

[4] Tomaž Erjavec. MULTEXT-East: Morphosyntactic resources for Central and Eastern European languages. *Language Resources and Evaluation*, 46(1):131--142, 2012. doi: 10.1007/s10579-011-9174-8.

[5] Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 10835--10866. PMLR, 2023. URL https://proceedings.mlr.press/v202/gao23h.html.

[6] Gemma Team. Gemma 4 technical report. arXiv preprint arXiv:2607.02770, 2026. URL https://arxiv.org/abs/2607.02770.

[7] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, Runxin Xu, Ruoyu Zhang, Shirong Ma, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Hanwei Xu, Honghui Ding, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jingchang Chen, Jingyang Yuan, Jinhao Tu, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaichao You, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Mingxu Zhou, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qiushi Du, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, R. J. Chen, R. L. Jin, Ruyi Chen, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shengfeng Ye, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, S. S. Li, Shuang Zhou, Shaoqing Wu, Tao Yun, Tian Pei, Tianyu Sun, T. Wang, Wangding

Zeng, Wen Liu, Wenfeng Liang, Wenjun Gao, Wenqin Yu, Wentao Zhang, W. L. Xiao, Wei An, Xiaodong Liu, Xiaohan Wang, Xiaokang Chen, Xiaotao Nie, Xin Cheng, Xin Liu, Xin Xie, Xingchao Liu, Xinyu Yang, Xinyuan Li, Xuecheng Su, Xuheng Lin, X. Q. Li, Xiangyue Jin, Xiaojin Shen, Xiaosha Chen, Xiaowen Sun, Xiaoxiang Wang, Xinnan Song, Xinyi Zhou, Xianzu Wang, Xinxia Shan, Y. K. Li, Y. Q. Wang, Y. X. Wei, Yang Zhang, Yanhong Xu, Yao Li, Yao Zhao, Yaofeng Sun, Yaohui Wang, Yi Yu, Yichao Zhang, Yifan Shi, Yiliang Xiong, Ying He, Yishi Piao, Yisong Wang, Yixuan Tan, Yiyang Ma, Yiyuan Liu, Yongqiang Guo, Yuan Ou, Yuduan Wang, Yue Gong, Yuheng Zou, Yujia He, Yunfan Xiong, Yuxiang Luo, Yuxiang You, Yuxuan Liu, Yuyang Zhou, Y. X. Zhu, Yanping Huang, Yaohui Li, Yi Zheng, Yuchen Zhu, Yunxian Ma, Ying Tang, Yukun Zha, Yuting Yan, Z. Z. Ren, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhicheng Ma, Zhigang Yan, Zhiyu Wu, Zihui Gu, Zijia Zhu, Zijun Liu, Zilin Li, Ziwei Xie, Ziyang Song, Zizheng Pan, Zhen Huang, Zhipeng Xu, Zhongyu Zhang, and Zhen Zhang. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*, 645(8081):633--638, 2025. doi: 10.1038/s41586-025-09422-z. Preprint: arXiv:2501.12948.

[8] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. arXiv preprint arXiv:1503.02531, 2015. URL https://arxiv.org/abs/1503.02531.

[9] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022. URL https://openreview.net/forum?id=nZeVKeeFYf9.

[10] Di Jin, Zhijing Jin, Zhiting Hu, Olga Vechtomova, and Rada Mihalcea. Deep learning for text style transfer: A survey. *Computational Linguistics*, 48(1):155--205, 2022. doi: 10.1162/coli_a_00426. URL https://aclanthology.org/2022.cl-1.6/.

[11] Yoon Kim and Alexander M. Rush. Sequence-level knowledge distillation. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 1317--1327, Austin, Texas, 2016. Association for Computational Linguistics. doi: 10.18653/v1/D16-1139. URL https://aclanthology.org/D16-1139/.

[12] Kalpesh Krishna, John Wieting, and Mohit Iyyer. Reformulating unsupervised style transfer as paraphrase generation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 737--762. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.emnlp-main.55. URL https://aclanthology.org/2020.emnlp-main.55/.

[13] Stefan Krsteski, Borjan Sazdov, Matea Tashkovska, Branislav Gerazov, and Hristijan Gjoreski. Towards open foundation language model and corpus for Macedonian: A low-resource language. In *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*, pages 44--57, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.bsnlp-1.6. URL https://aclanthology.org/2025.bsnlp-1.6/.

[14] Juncen Li, Robin Jia, He He, and Percy Liang. Delete, retrieve, generate: a simple approach to sentiment and style transfer. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language*

Technologies, Volume 1 (Long Papers), pages 1865--1874, New Orleans, Louisiana, 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-1169. URL https://aclanthology.org/N18-1169/.

[15] Pusheng Liu, Lianwei Wu, Linyong Wang, Sensen Guo, and Yang Liu. Step-by-step: Controlling arbitrary style in text with large language models. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 15285--15295, Torino, Italia, 2024. ELRA and ICCL. URL https://aclanthology.org/2024.lrec-main.1328/.

[16] Nikola Ljubešić and Kaja Dobrovoljc. What does neural bring? analysing improvements in morphosyntactic annotation and lemmatisation of Slovenian, Croatian and Serbian. In *Proceedings of the 7th Workshop on Balto-Slavic Natural Language Processing*, pages 29--34, Florence, Italy, 2019. Association for Computational Linguistics. doi: 10.18653/v1/W19-3704. URL https://aclanthology.org/W19-3704/.

[17] Fuli Luo, Peng Li, Jie Zhou, Pengcheng Yang, Baobao Chang, Xu Sun, and Zhifang Sui. A dual reinforcement learning framework for unsupervised text style transfer. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19)*, pages 5116--5122. International Joint Conferences on Artificial Intelligence Organization, 2019. doi: 10.24963/ijcai.2019/711.

[18] Frederick Mosteller and David L. Wallace. *Inference and Disputed Authorship: The Federalist*. Addison-Wesley Series in Behavioral Science: Quantitative Methods. Addison-Wesley, Reading, MA, 1964. URL https://casbs.stanford.edu/inference-and-disputed-authorship-federalist.

[19] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35, pages 27730--27744. Curran Associates, Inc., 2022. doi: 10.52202/068431-2011. URL https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html.

[20] Peng Qi, Yuhao Zhang, Yuhui Zhang, Jason Bolton, and Christopher D. Manning. Stanza: A Python natural language processing toolkit for many human languages. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*, pages 101--108. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-demos.14. URL https://aclanthology.org/2020.acl-demos.14/.

[21] Sudha Rao and Joel Tetreault. Dear sir or madam, may I introduce the GYAFC dataset: Corpus, benchmarks and metrics for formality style transfer. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 129--140, New Orleans, Louisiana, 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-1012. URL https://aclanthology.org/N18-1012/.

[22] Emily Reif, Daphne Ippolito, Ann Yuan, Andy Coenen, Chris Callison-Burch, and Jason Wei. A recipe for arbitrary text style transfer with large language models. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 837--848, Dublin, Ireland, 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.acl-short.94. URL https://aclanthology.org/2022.acl-short.94/.

[23] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017. URL https://arxiv.org/abs/1707.06347.

[24] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024. URL https://arxiv.org/abs/2402.03300.

[25] Tianxiao Shen, Tao Lei, Regina Barzilay, and Tommi Jaakkola. Style transfer from non-parallel text by cross-alignment. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/2d2c8394e31101a261abf1784302bf75-Abstract.html.

[26] Joar Skalse, Nikolaus Howe, Dmitrii Krasheninnikov, and David Krueger. Defining and characterizing reward gaming. In *Advances in Neural Information Processing Systems*, volume 35, pages 9460--9471. Curran Associates, Inc., 2022. doi: 10.52202/068431-0687. URL https://proceedings.neurips.cc/paper_files/paper/2022/hash/3d719fee332caa23d5038b8a90e81796-Abstract-Conference.html.

[27] Efstathios Stamatatos. A survey of modern authorship attribution methods. *Journal of the American Society for Information Science and Technology*, 60(3):538--556, 2009. doi: 10.1002/asi.21001.

[28] Luka Terčon and Nikola Ljubešić. CLASSLA-Stanza: The next step for linguistic processing of South Slavic languages. arXiv preprint arXiv:2308.04255, 2023. URL https://arxiv.org/abs/2308.04255.

[29] Alexey Tikhonov and Ivan P. Yamshchikov. Guess who? Multilingual approach for the automated generation of author-stylized poetry. In *2018 IEEE Spoken Language Technology Workshop (SLT)*, pages 787--794. IEEE, 2018. doi: 10.1109/SLT.2018.8639573.

[30] Leandro von Werra, Younes Belkada, Lewis Tunstall, Edward Beeching, Tristan Thrush, Nathan Lambert, Shengyi Huang, Kashif Rasul, and Quentin Gallouédec. TRL: Transformers reinforcement learning. https://github.com/huggingface/trl, 2020. URL https://github.com/huggingface/trl. Software, Apache-2.0 license.

[31] Yizhong Wang, Yeganeh Kordi, Swaroop Mishra, Alisa Liu, Noah A. Smith, Daniel Khashabi, and Hannaneh Hajishirzi. Self-instruct: Aligning language models with self-generated instructions. In *Proceedings of the 61st Annual Meeting of the Association*

for Computational Linguistics (Volume 1: Long Papers), pages 13484--13508, Toronto, Canada, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.754. URL https://aclanthology.org/2023.acl-long.754/.

[32] Wei Xu, Alan Ritter, Bill Dolan, Ralph Grishman, and Colin Cherry. Paraphrasing for style. In *Proceedings of COLING 2012*, pages 2899--2914, Mumbai, India, 2012. The COLING 2012 Organizing Committee. URL https://aclanthology.org/C12-1177/.

[33] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, Chujie Zheng, Dayiheng Liu, Fan Zhou, Fei Huang, Feng Hu, Hao Ge, Haoran Wei, Huan Lin, Jialong Tang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jing Zhou, Jingren Zhou, Junyang Lin, Kai Dang, Keqin Bao, Kexin Yang, Le Yu, Lianghao Deng, Mei Li, Mingfeng Xue, Mingze Li, Pei Zhang, Peng Wang, Qin Zhu, Rui Men, Ruize Gao, Shixuan Liu, Shuang Luo, Tianhao Li, Tianyi Tang, Wenbiao Yin, Xingzhang Ren, Xinyu Wang, Xinyu Zhang, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yinger Zhang, Yu Wan, Yuqiong Liu, Zekun Wang, Zeyu Cui, Zhenru Zhang, Zhipeng Zhou, and Zihan Qiu. Qwen3 technical report. arXiv preprint arXiv:2505.09388, 2025. URL https://arxiv.org/abs/2505.09388.

[34] Daniel M. Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B. Brown, Alec Radford, Dario Amodei, Paul Christiano, and Geoffrey Irving. Fine-tuning language models from human preferences. arXiv preprint arXiv:1909.08593, 2019. URL https://arxiv.org/abs/1909.08593.

[35] Лидија Аризанковска and Андријана Павлова. Македонскиот јазик и вештачката интелигенција: неколку зборови за македонскиот јазик на ChatGPT. In *Зборник на трудови од VIII меѓународна научна конференција „Крсте Мисирков и македонскиот јазик – извор на научни истражувања“*, pages 11--22, Скопје, 2024. Институт за македонски јазик „Крсте Мисирков“.